UNIVERSIDADE PRESBITERIANA MACKENZIE

SABRINA VITORIA BASTOS DOS SANTOS

ANÁLISE DA SUPERLOTAÇÃO NO SISTEMA METROVIÁRIO DE SÃO PAULO: UM ESTUDO EXPLORATÓRIO DO FLUXO DE PASSAGEIROS

SÃO PAULO, SP

2026

SABRINA VITORIA BASTOS DOS SANTOS

ANÁLISE DA SUPERLOTAÇÃO NO SISTEMA METROVIÁRIO DE SÃO PAULO: UM ESTUDO EXPLORATÓRIO DO FLUXO DE PASSAGEIROS

Projeto aplicado apresentado à Faculdade de Informática da Universidade Presbiteriana Mackenzie, como requisito parcial para avaliação na disciplina Projeto Aplicado I.
Área de concentração: Banco de Dados

Orientador: Prof. FABIO LOPES

SÃO PAULO, SP

2026

Sumário

1. CONTEXTO DO ESTUDO 2
2. REFERÊNCIAS DE AQUISIÇÃO DO DATASET 2
3. DESCRIÇÃO DA ORIGEM DOS DADOS 3
4. DESCRIÇÃO DO DATASET 3
5. DESCRIÇÃO DO METADADOS 3
6. PROPOSTA ANALÍTICA 4
7. ANÁLISE EXPLORATÓRIA DE DADOS 6

INTRODUÇÃO

A mobilidade urbana é um dos principais desafios enfrentados por grandes centros metropolitanos, especialmente em cidades com alta densidade populacional e intensa atividade econômica, como São Paulo. Nesse cenário, o transporte público desempenha um papel fundamental na garantia do deslocamento eficiente da população, sendo o sistema metroviário um dos pilares dessa infraestrutura.

O sistema metroviário da cidade, operado pela Companhia do Metropolitano de São Paulo e complementado por concessões à iniciativa privada, como a ViaMobilidade, é responsável pelo transporte diário de milhões de passageiros. Sua relevância está diretamente associada à capacidade de reduzir congestionamentos, otimizar o tempo de deslocamento e promover maior acessibilidade urbana.

Apesar de sua importância, o sistema enfrenta desafios significativos, dentre os quais se destaca a superlotação, especialmente nos horários de pico. Esse fenômeno compromete a qualidade do serviço prestado, impactando negativamente o conforto, a segurança e a experiência dos usuários, além de impor limitações operacionais à gestão do sistema.

A superlotação não ocorre de maneira uniforme, variando conforme fatores como linha, estação, horário e dia da semana. Dessa forma, compreender o comportamento do fluxo de passageiros torna-se essencial para identificar padrões de demanda e subsidiar estratégias de melhoria na operação do sistema metroviário.

1. CONTEXTO DO ESTUDO

O presente estudo está inserido no contexto da mobilidade urbana da cidade de São Paulo, uma das maiores metrópoles do mundo, caracterizada por elevada densidade populacional e intensa demanda por transporte público.

Nesse cenário, o sistema metroviário, operado pela Companhia do Metropolitano de São Paulo (Metrô de São Paulo), desempenha um papel essencial no deslocamento diário da população, transportando milhões de passageiros diariamente. A organização atua no setor de transporte público urbano, com foco na operação de sistemas metroviários.

Apesar de sua relevância, o sistema enfrenta desafios operacionais significativos, dentre os quais se destaca a superlotação, especialmente nos horários de pico em dias úteis. Esse fenômeno impacta diretamente a qualidade do serviço, afetando o conforto, a segurança e a eficiência do transporte.

Dessa forma, este estudo tem como objetivo analisar o fluxo de passageiros no sistema metroviário de São Paulo, com foco na identificação de padrões de demanda e na compreensão da distribuição da superlotação entre as diferentes estações, bem como sua variação ao longo do tempo.

2. REFERÊNCIAS DE AQUISIÇÃO DO DATASET

Os dados utilizados neste estudo foram obtidos a partir de fontes públicas disponibilizadas pela Companhia do Metropolitano de São Paulo (Metrô de São Paulo).

Foram selecionados dois conjuntos de dados: Demanda de Passageiros por Estação – Média de Dias Úteis – 2025 e Demanda de Passageiros por Estação – Média de Dias Úteis – 2026.

A utilização de dois períodos distintos permite a realização de uma análise comparativa, possibilitando a identificação de variações na demanda ao longo do tempo. Limitações de uso: Os dados são públicos e destinados a fins acadêmicos, representam valores médios de dias úteis, não incluem finais de semana e não apresentam detalhamento por faixa horária.

Período da coleta: Anos de referência 2025 e 2026, com dados agregados em forma de média de movimentação em dias úteis.

3. DESCRIÇÃO DA ORIGEM DOS DADOS

Os dados analisados neste estudo são gerados pela Companhia do Metropolitano de São Paulo (Metrô de São Paulo), empresa pública responsável pela operação de grande parte do sistema metroviário da cidade.

A coleta dessas informações ocorre por meio de sistemas automatizados de bilhetagem eletrônica, que registram o fluxo de passageiros nas catracas das estações. Dessa forma, os dados são processados e agregados, resultando em métricas como a média de passageiros por estação em dias úteis.

O contexto de geração desses dados está diretamente relacionado à operação cotidiana do transporte público, refletindo o comportamento real dos usuários.

4. DESCRIÇÃO DO DATASET

O presente estudo utiliza dois datasets que apresentam informações sobre a demanda média de passageiros por estação do metrô de São Paulo em dias úteis nos anos de 2025 e 2026.

As bases possuem variáveis como nome da estação, linha do metrô e demanda média de passageiros. A proposta dos datasets é representar o volume médio de utilização do sistema, permitindo a análise da distribuição da demanda entre as estações e os índices de superlotação, podendo ao longo do estudo ser adicionado novas bases de dados para enriquecimento do estudo.

A utilização conjunta dos dados possibilita identificar variações no fluxo de passageiros, crescimento ou redução da demanda, mudanças na distribuição entre linhas e indícios de superlotação.

Embora os dados sejam agregados, eles são adequados para identificar padrões gerais e tendências no comportamento da demanda.

5. DESCRIÇÃO DO METADADOS

A base de dados utilizada neste estudo é estruturada e tabular, contendo informações sobre a demanda média de passageiros por estação do sistema metroviário de São Paulo em dias úteis. Os datasets analisados correspondem aos anos de 2025 e 2026 e apresentam, como principais variáveis, o nome da estação, a linha à qual a estação pertence, o mês de referência e o volume médio de passageiros.

A granularidade da base é espacial e temporal em nível mensal, permitindo observar a

distribuição da demanda entre estações e sua variação ao longo dos meses. Assim, a base é adequada para identificar padrões gerais de concentração de passageiros, estações com maior carregamento e diferenças entre os períodos analisados.

Do ponto de vista metodológico, trata-se de um conjunto de dados quantitativos e estruturados, apropriado para técnicas de análise exploratória, estatística descritiva e visualização de dados. Entre as análises realizadas, destacam-se a identificação de valores máximos e mínimos, medidas de tendência central, dispersão, presença de valores ausentes e comparação entre anos.

Como limitação, a base não apresenta detalhamento por faixa horária, nem informações individualizadas de embarque e desembarque, o que impede análises mais finas sobre horários de pico. Ainda assim, os dados são adequados para um estudo exploratório voltado à identificação de estações e períodos com maior pressão de demanda.

6. PROPOSTA ANALÍTICA

1.1 Organização/Empresa analisada

A organização analisada neste estudo é a Companhia do Metropolitano de São Paulo (Metrô de São Paulo), responsável pela operação de parte relevante do sistema metroviário da capital paulista. A empresa atua no setor de mobilidade urbana e transporte público, exercendo papel estratégico no deslocamento diário de milhões de passageiros.

2.2 Problema do estudo

O problema investigado neste projeto consiste na identificação de padrões de demanda e de possíveis indícios de superlotação no sistema metroviário de São Paulo. Embora a superlotação seja um fenômeno recorrente no transporte urbano, sua distribuição não ocorre de forma homogênea entre estações e períodos do ano. Dessa forma, torna-se relevante analisar quais estações concentram maior volume médio de passageiros e em quais meses essa demanda se intensifica.

2.3 Objetivo geral

Analisar o fluxo médio de passageiros por estação no sistema metroviário de São Paulo, com base nos dados de 2025 e 2026, a fim de identificar padrões de demanda, estações com maior movimentação e variações temporais entre os períodos observados.

2.4 Objetivos específicos

- Organizar e tratar os datasets públicos selecionados.
- Identificar as estações com maior demanda média de passageiros.
- Verificar o mês de maior movimento em cada estação.
- Comparar o comportamento da demanda entre os anos de 2025 e 2026.
- Produzir tabelas e gráficos que apoiem a interpretação dos resultados.

2.5 Proposta do produto analítico

O produto analítico desenvolvido neste trabalho consiste em uma análise exploratória dos dados de demanda de passageiros por estação, utilizando Python em notebooks Jupyter. O foco do produto é apoiar a compreensão da distribuição da demanda no sistema metroviário, evidenciando as estações mais carregadas, os meses de maior movimento e as diferenças observadas entre os dois anos analisados. Como resultado, espera-se gerar tabelas sintéticas, rankings e visualizações gráficas que auxiliem na interpretação dos padrões de superlotação média no sistema.

2.6 Pipeline de dados

O pipeline analítico proposto é composto pelas seguintes etapas:

1. Coleta dos datasets públicos referentes à demanda média de passageiros por estação em dias úteis nos anos de 2025 e 2026.
2. Leitura dos arquivos CSV em ambiente Python.
3. Limpeza e padronização dos dados, com tratamento de cabeçalhos, remoção de linhas indevidas e conversão de valores numéricos.
4. Transformação dos dados para formato analítico, permitindo comparações por estação, linha, mês e ano.
5. Aplicação de análise exploratória de dados, com geração de estatísticas descritivas e visualizações.
6. Interpretação dos resultados, destacando padrões de demanda e limitações da base.
7. Publicação dos scripts no GitHub como evidência do processo analítico.

7. ANÁLISE EXPLORATÓRIA DE DADOS

1.1 Objetivo da análise exploratória

A análise exploratória de dados teve como finalidade compreender a estrutura dos datasets utilizados, verificar a qualidade dos dados, identificar padrões de distribuição da demanda de passageiros e apontar possíveis concentrações de fluxo no sistema metroviário de São Paulo.

1.2 Estrutura da base

Após o tratamento dos arquivos, a base consolidada passou a apresentar as seguintes variáveis analíticas:

- **Estação**: nome da estação do metrô.
- **Linha**: linha à qual a estação pertence.
- **Ano**: ano de referência do dataset.
- **Mes**: mês de referência da observação.
- **Passageiros**: volume médio de passageiros registrado para a estação no mês analisado.

A transformação dos dados para formato longo possibilitou maior flexibilidade para comparações entre meses, estações e anos.

1.3 Qualidade dos dados

Durante o pré-processamento, foram removidas linhas que correspondiam a títulos, totais e observações textuais presentes no arquivo original. Também foi realizada a padronização dos valores numéricos, convertendo os campos mensais para formato quantitativo. Registros sem valor numérico válido foram tratados como ausentes e excluídos das análises comparativas.

1.4 Estatísticas descritivas

Foram calculadas medidas de tendência central e dispersão para a variável de demanda de passageiros, incluindo média, mediana, valor mínimo, valor máximo, desvio-padrão e quartis. Essas medidas permitiram avaliar o comportamento geral da distribuição e identificar a existência de grande variabilidade entre as estações.

1.5 Valores ausentes

A análise de valores ausentes teve como objetivo verificar a integridade dos dados após o processo de transformação. Os registros com ausência de valor para a demanda mensal foram identificados e tratados, evitando interferências nos cálculos estatísticos e nas visualizações.

1.6 Distribuição da demanda

A distribuição da variável de passageiros foi observada por meio de tabelas e gráficos, permitindo identificar a concentração dos valores em determinadas faixas e evidenciando a existência de estações com demanda muito superior à média do sistema.

1.7 Análise de outliers

A verificação de outliers foi realizada com base em medidas estatísticas e representação gráfica. Estações com valores muito elevados em relação ao conjunto foram interpretadas não necessariamente como erros, mas como possíveis pontos críticos de alta concentração de demanda, o que é coerente com o objetivo do estudo.

1.8 Principais achados exploratórios

A análise exploratória indicou que:

- há forte heterogeneidade na distribuição da demanda entre as estações;
- algumas estações como sé concentram volumes médios significativamente superiores às demais;
- a demanda varia ao longo dos meses;
- a comparação entre 2025 e 2026 permite observar mudanças no comportamento médio do fluxo de passageiros.

3.9 Limitações da análise

A principal limitação da análise exploratória está relacionada à granularidade dos dados, que são agregados por estação e mês. Dessa forma, não foi possível identificar horários específicos de pico ou analisar o comportamento intradiário da superlotação.