

UNIVERSIDADE PRESBITERIANA MACKENZIE

SABRINA VITORIA BASTOS DOS SANTOS

**ANÁLISE DA SUPERLOTAÇÃO NO SISTEMA METROVIÁRIO DE SÃO PAULO:
UM ESTUDO EXPLORATÓRIO DO FLUXO DE PASSAGEIROS**

SÃO PAULO, SP

2026

SABRINA VITORIA BASTOS DOS SANTOS

**ANÁLISE DA SUPERLOTAÇÃO NO SISTEMA METROVIÁRIO DE SÃO PAULO:
UM ESTUDO EXPLORATÓRIO DO FLUXO DE PASSAGEIROS**

Projeto aplicado apresentado à Faculdade de
Informática da
Universidade Presbiteriana Mackenzie, como
requisito parcial para
avaliação na disciplina Projeto Aplicado I.
Área de concentração: Banco de Dados

Orientador: Prof. FABIO LOPES

SÃO PAULO, SP

2026

Sumário

SÃO PAULO, SP 2026	2
1. CONTEXTO DO ESTUDO	2
2. REFERÊNCIAS DE AQUISIÇÃO DO DATASET.....	2
3. DESCRIÇÃO DA ORIGEM DOS DADOS.....	3
4. DESCRIÇÃO DO DATASET.....	3
5. DESCRIÇÃO DO METADADOS.....	3
6. PROPOSTA ANALÍTICA	4
7. ANÁLISE EXPLORATÓRIA DE DADOS	7
8. PROPOSTA ANALÍTICA	11

INTRODUÇÃO

A mobilidade urbana é um dos principais desafios enfrentados por grandes centros metropolitanos, especialmente em cidades com alta densidade populacional e intensa atividade econômica, como São Paulo. Nesse cenário, o transporte público desempenha um papel fundamental na garantia do deslocamento eficiente da população, sendo o sistema metroviário um dos pilares dessa infraestrutura.

O sistema metroviário da cidade, operado pela Companhia do Metropolitano de São Paulo e complementado por concessões à iniciativa privada, como a ViaMobilidade, é responsável pelo transporte diário de milhões de passageiros. Sua relevância está diretamente associada à capacidade de reduzir congestionamentos, otimizar o tempo de deslocamento e promover maior acessibilidade urbana.

Apesar de sua importância, o sistema enfrenta desafios significativos, dentre os quais se destaca a superlotação, especialmente nos horários de pico. Esse fenômeno compromete a qualidade do serviço prestado, impactando negativamente o conforto, a segurança e a experiência dos usuários, além de impor limitações operacionais à gestão do sistema.

A superlotação não ocorre de maneira uniforme, variando conforme fatores como linha, estação, horário e dia da semana. Dessa forma, compreender o comportamento do fluxo de passageiros torna-se essencial para identificar padrões de demanda e subsidiar estratégias de melhoria na operação do sistema metroviário.

1. CONTEXTO DO ESTUDO

O presente estudo está inserido no contexto da mobilidade urbana da cidade de São Paulo, uma das maiores metrópoles do mundo, caracterizada por elevada densidade populacional e intensa demanda por transporte público.

Nesse cenário, o sistema metroviário, operado pela Companhia do Metropolitano de São Paulo (Metrô de São Paulo), desempenha um papel essencial no deslocamento diário da população, transportando milhões de passageiros diariamente. A organização atua no setor de transporte público urbano, com foco na operação de sistemas metroviários.

Apesar de sua relevância, o sistema enfrenta desafios operacionais significativos, dentre os quais se destaca a superlotação, especialmente nos horários de pico em dias úteis. Esse fenômeno impacta diretamente a qualidade do serviço, afetando o conforto, a segurança e a eficiência do transporte.

Dessa forma, este estudo tem como objetivo analisar o fluxo de passageiros no sistema metroviário de São Paulo, com foco na identificação de padrões de demanda e na compreensão da distribuição da superlotação entre as diferentes estações, bem como sua variação ao longo do tempo.

2. REFERÊNCIAS DE AQUISIÇÃO DO DATASET

Os dados utilizados neste estudo foram obtidos a partir de fontes públicas disponibilizadas pela Companhia do Metropolitano de São Paulo (Metrô de São Paulo).

Foram selecionados dois conjuntos de dados: Demanda de Passageiros por Estação – Média de Dias Úteis – 2025 e Demanda de Passageiros por Estação – Média de Dias Úteis – 2026.

A utilização de dois períodos distintos permite a realização de uma análise comparativa, possibilitando a identificação de variações na demanda ao longo do tempo. Limitações de uso: Os dados são públicos e destinados a fins acadêmicos, representam valores médios de dias úteis, não incluem finais de semana e não apresentam detalhamento por faixa horária.

Período da coleta: Anos de referência 2025 e 2026, com dados agregados em forma de média de movimentação em dias úteis.

3. DESCRIÇÃO DA ORIGEM DOS DADOS

Os dados analisados neste estudo são gerados pela Companhia do Metropolitano de São Paulo (Metrô de São Paulo), empresa pública responsável pela operação de grande parte do sistema metroviário da cidade.

A coleta dessas informações ocorre por meio de sistemas automatizados de bilhetagem eletrônica, que registram o fluxo de passageiros nas catracas das estações. Dessa forma, os dados são processados e agregados, resultando em métricas como a média de passageiros por estação em dias úteis.

O contexto de geração desses dados está diretamente relacionado à operação cotidiana do transporte público, refletindo o comportamento real dos usuários.

4. DESCRIÇÃO DO DATASET

O presente estudo utiliza dois datasets que apresentam informações sobre a demanda média de passageiros por estação do metrô de São Paulo em dias úteis nos anos de 2025 e 2026.

As bases possuem variáveis como nome da estação, linha do metrô e demanda média de passageiros. A proposta dos datasets é representar o volume médio de utilização do sistema, permitindo a análise da distribuição da demanda entre as estações e os índices de superlotação, podendo ao longo do estudo ser adicionado novas bases de dados para enriquecimento do estudo.

A utilização conjunta dos dados possibilita identificar variações no fluxo de passageiros, crescimento ou redução da demanda, mudanças na distribuição entre linhas e indícios de superlotação.

Embora os dados sejam agregados, eles são adequados para identificar padrões gerais e tendências no comportamento da demanda.

5. DESCRIÇÃO DO METADADOS

A base de dados consolidada para a análise é estruturada em formato longo (*meltd*) e possui as seguintes características técnicas:

Nome da Coluna	Tipo de Dado	Descrição	Exemplo de Conteúdo
Estacao	Texto (String)	Nome oficial da estação de metrô.	"Sé", "Paraíso"
Linha	Texto (String)	Identificação da linha à qual a estação	"Linha 1 -

		pertence.	Azul"
Ano	Inteiro (Int)	Ano de referência da coleta dos dados.	2025, 2026
Mes	Texto (String)	Abreviação de três letras correspondente ao mês de referência.	"Jan", "Fev"
Passageiros	Numérico (Float/Int)	Média diária de passageiros que utilizaram a estação em dias úteis.	150230.50

A granularidade da base é espacial e temporal em nível mensal, permitindo observar a distribuição da demanda entre estações e sua variação ao longo dos meses. Assim, a base é adequada para identificar padrões gerais de concentração de passageiros, estações com maior carregamento e diferenças entre os períodos analisados.

Do ponto de vista metodológico, trata-se de um conjunto de dados quantitativos e estruturados, apropriado para técnicas de análise exploratória, estatística descritiva e visualização de dados. Entre as análises realizadas, destacam-se a identificação de valores máximos e mínimos, medidas de tendência central, dispersão, presença de valores ausentes e comparação entre anos.

Como limitação, a base não apresenta detalhamento por faixa horária, nem informações individualizadas de embarque e desembarque, o que impede análises mais finas sobre horários de pico. Ainda assim, os dados são adequados para um estudo exploratório voltado à identificação de estações e períodos com maior pressão de demanda.

6. PROPOSTA ANALÍTICA

1.1 Organização/Empresa analisada

A organização analisada neste estudo é a Companhia do Metropolitano de São Paulo (Metrô de São Paulo), responsável pela operação de parte relevante do sistema metroviário da capital paulista. A empresa atua no setor de mobilidade urbana e transporte público, exercendo papel estratégico no deslocamento diário de milhões de passageiros.

2.2 Problema do estudo

O problema investigado neste projeto consiste na identificação de padrões de demanda e de possíveis indícios de superlotação no sistema metroviário de São Paulo. Embora a superlotação seja um fenômeno recorrente no transporte urbano, sua distribuição não ocorre de forma homogênea entre estações e períodos do ano. Dessa forma, torna-se relevante analisar quais estações concentram maior volume médio de passageiros e em quais meses essa demanda se

intensifica.

2.3 Objetivo geral

Analisar o fluxo médio de passageiros por estação no sistema metroviário de São Paulo, com base nos dados de 2025 e 2026, a fim de identificar padrões de demanda, estações com maior movimentação e variações temporais entre os períodos observados.

2.4 Objetivos específicos

- Organizar e tratar os datasets públicos selecionados.
- Identificar as estações com maior demanda média de passageiros.
- Verificar o mês de maior movimento em cada estação.
- Comparar o comportamento da demanda entre os anos de 2025 e 2026.
- Produzir tabelas e gráficos que apoiem a interpretação dos resultados.

2.5 Proposta do produto analítico

O produto analítico desenvolvido neste trabalho consiste em uma análise exploratória dos dados de demanda de passageiros por estação, utilizando Python em notebooks Jupyter. O foco do produto é apoiar a compreensão da distribuição da demanda no sistema metroviário, evidenciando as estações mais carregadas, os meses de maior movimento e as diferenças observadas entre os dois anos analisados. Como resultado, espera-se gerar tabelas sintéticas, rankings e visualizações gráficas que auxiliem na interpretação dos padrões de superlotação média no sistema.

2.6 Pipeline de dados

O pipeline analítico proposto é composto pelas seguintes etapas:

1. Coleta dos datasets públicos referentes à demanda média de passageiros por estação em dias úteis nos anos de 2025 e 2026.
2. Leitura dos arquivos CSV em ambiente Python.
3. Limpeza e padronização dos dados, com tratamento de cabeçalhos, remoção de linhas indevidas e conversão de valores numéricos.
4. Transformação dos dados para formato analítico, permitindo comparações por estação, linha, mês e ano.

5. Aplicação de análise exploratória de dados, com geração de estatísticas descritivas e visualizações.
6. Interpretação dos resultados, destacando padrões de demanda e limitações da base.
7. Publicação dos scripts no GitHub como evidência do processo analítico.

Link de Acesso ao Repositório do Projeto (GitHub): > <https://github.com/seu-usuario/seu-repositorio>

7. ANÁLISE EXPLORATÓRIA DE DADOS

1.1 Objetivo da análise exploratória

A análise exploratória de dados teve como finalidade compreender a estrutura dos datasets utilizados, verificar a qualidade dos dados, identificar padrões de distribuição da demanda de passageiros e apontar possíveis concentrações de fluxo no sistema metroviário de São Paulo.

1.2 Estrutura da base

Após o tratamento dos arquivos, a base consolidada passou a apresentar as seguintes variáveis analíticas:

- **Estação:** nome da estação do metrô.
- **Linha:** linha à qual a estação pertence.
- **Ano:** ano de referência do dataset.
- **Mes:** mês de referência da observação.
- **Passageiros:** volume médio de passageiros registrado para a estação no mês analisado.

A transformação dos dados para formato longo possibilitou maior flexibilidade para comparações entre meses, estações e anos.

1.3 Qualidade dos dados

Durante o pré-processamento, foram removidas linhas que correspondiam a títulos, totais e observações textuais presentes no arquivo original. Também foi realizada a padronização dos valores numéricos, convertendo os campos mensais para formato quantitativo. Registros sem valor numérico válido foram tratados como ausentes e excluídos das análises comparativas.

1.4 Estatísticas descritivas

Foram calculadas medidas de tendência central e dispersão para a variável de demanda de passageiros, incluindo média, mediana, valor mínimo, valor máximo, desvio-padrão e quartis. Essas medidas permitiram avaliar o comportamento geral da distribuição e identificar a existência de grande variabilidade entre as estações, chegando ao resultado:

VISÃO GERAL DA BASE TRATADA

```

Total de registros 2025: 516
Total de registros 2026: 86
Total geral: 602
Quantidade de estações: 55
Quantidade de linhas: 3

```

ESTATÍSTICA DESCRITIVA

	count	mean	std	min	25%	50%	75%	max
Ano								
2025	516.0	43.71	40.70	3.0	15.00	28.0	65.0	212.0
2026	86.0	41.65	39.13	4.0	14.25	26.0	61.5	202.0

1.5 Valores ausentes

A análise de valores ausentes teve como objetivo verificar a integridade dos dados após o processo de transformação. Os registros com ausência de valor para a demanda mensal foram identificados e tratados, evitando interferências nos cálculos estatísticos e nas visualizações.

1.6 Distribuição da demanda

A distribuição da variável de passageiros foi observada por meio de tabelas e gráficos, permitindo identificar a concentração dos valores em determinadas faixas e evidenciando a existência de estações com demanda muito superior à média do sistema. Segundo o resultado da análise, a estação do metro mais lotada seria a SÉ, uma dos pontos mais centrais de São Paulo que conecta a linha três vermelha do metro a linha um azul do metro. Tal estação recebe cerca de 212mil passageiros por dia segundo dados de 2025, disponibilizados pelo metro.

 TOP 10 ESTAÇÕES MAIS LOTADAS
 =====

		Estacao	Linha	Passageiros
42		SÉ¹	LINHA 3-VERMELHA	212.0
41		SÉ (1)	LINHA 3-VERMELHA	202.0
26	PALMEIRAS-BARRA FUNDA ²		LINHA 3-VERMELHA	151.0
25	PALMEIRAS-BARRA FUNDA (2)		LINHA 3-VERMELHA	146.0
33		REPÚBLICA ³	LINHA 3-VERMELHA	127.0
32		REPÚBLICA (3)	LINHA 3-VERMELHA	121.0
16		CONSOLAÇÃO *	LINHA 2-VERDE	105.0
15		CONSOLAÇÃO (4)	LINHA 2-VERDE	100.0
13		CHÁCARA KLABIN ³	LINHA 2-VERDE	90.0
52		VILA PRUDENTE ¹	LINHA 2-VERDE	90.0


=====

ESTAÇÃO MAIS LOTADA POR MÊS

=====

	Ano	Mes	Estacao	Linha	Passageiros
0	2025	Abr	SÉ¹	LINHA 3-VERMELHA	212.0
1	2025	Ago	SÉ¹	LINHA 3-VERMELHA	203.0
2	2025	Dez	SÉ¹	LINHA 3-VERMELHA	193.0
3	2025	Fev	SÉ¹	LINHA 3-VERMELHA	204.0
4	2025	Jan	SÉ¹	LINHA 3-VERMELHA	176.0
5	2025	Jul	SÉ¹	LINHA 3-VERMELHA	186.0
6	2025	Jun	SÉ¹	LINHA 3-VERMELHA	200.0
7	2025	Mai	SÉ¹	LINHA 3-VERMELHA	209.0
8	2025	Mar	SÉ¹	LINHA 3-VERMELHA	210.0
9	2025	Nov	SÉ¹	LINHA 3-VERMELHA	210.0

12	2026	Fev	SÉ (1)	LINHA 3-VERMELHA	202.0
13	2026	Jan	SÉ (1)	LINHA 3-VERMELHA	179.0



1.7 Análise de outliers

A verificação de outliers foi realizada com base em medidas estatísticas e representação gráfica. Estações com valores muito elevados em relação ao conjunto foram interpretadas não necessariamente como erros, mas como possíveis pontos críticos de alta concentração de demanda, o que é coerente com o objetivo do estudo.

1.8 Principais achados exploratórios

A análise exploratória indicou que:

- há forte heterogeneidade na distribuição da demanda entre duas principais linha de metro: vermelha e azul;
- algumas estações como sé concentram volumes médios significativamente superiores às demais, isso se deve a um ponto importante. A localização;
- a demanda varia ao longo dos meses, mas não possui certa dispariedade;
- a comparação entre 2025 e 2026 permite observar mudanças no comportamento médio do fluxo de passageiros.

3.9 Limitações da análise

A principal limitação da análise exploratória está relacionada à granularidade dos dados, que são agregados por estação e mês. Dessa forma, não foi possível identificar horários específicos de pico ou analisar o comportamento intradiário da superlotação.

8. PROPOSTA ANALÍTICA

1. O SETUP (O Contexto e o Protagonista)

A mobilidade urbana representa um dos maiores e mais complexos desafios enfrentados pelas grandes metrópoles globais. Em uma cidade como São Paulo, caracterizada por uma altíssima densidade populacional e uma atividade econômica pulsante e ininterrupta, o transporte público não é apenas uma conveniência, mas sim uma infraestrutura vital para a sobrevivência e o funcionamento do município.

Nesse cenário, o nosso protagonista é o **sistema metroviário**, operado pela Companhia do Metropolitano de São Paulo (Metrô). Ele atua como o verdadeiro coração da engenharia de tráfego paulistana, sendo o pilar essencial para garantir o deslocamento diário, rápido e de massa para milhões de trabalhadores, estudantes e cidadãos, conectando as diferentes zonas da capital e reduzindo o impacto severo dos congestionamentos na superfície.

2. O CONFLITO (O Incidente e o Impacto)

Embora o sistema metroviário desempenhe esse papel indispensável, quem utiliza a rede no cotidiano enfrenta de perto o grande antagonista desta jornada urbana: **a superlotação**. Esse fenômeno compromete diretamente a eficiência operacional, deteriora o conforto dos usuários e gera gargalos críticos de segurança e bem-estar nas plataformas.

O grande problema (*gap* de informação) reside no fato de que o fluxo de passageiros não é distribuído de forma homogênea. Para que a governança do Metrô de São Paulo possa aplicar melhorias ou estratégias de manejo de fluxo, surgem perguntas cruciais e urgentes: *Quais estações sofrem a maior pressão de demanda? Como esse comportamento flutua ao longo do tempo e quais foram as principais variações observadas entre os anos de 2025 e 2026?* Sem uma análise baseada em evidências, o planejamento operacional torna-se reativo. A ausência de uma visão analítica clara sobre esses picos de concentração impede a aplicação de intervenções logísticas eficientes.

3. A JORNADA COM OS DADOS (A Proposta Analítica)

Para solucionar esse conflito e encontrar respostas concretas, foi desenvolvida uma abordagem estruturada de Ciência de Dados. Utilizando a linguagem de programação Python e o ambiente Jupyter Notebook, foi implementado um pipeline analítico focado em processar dados públicos e oficiais de demanda disponibilizados pelo próprio Metrô de São Paulo.

O estudo concentrou-se nos registros da demanda média de passageiros que ingressam no sistema em dias úteis, cobrindo de forma comparativa os anos de 2025 e 2026. Na etapa de tratamento de dados (*data cleaning*), as bases brutas foram limpas e remodeladas para o formato longo (*melted*), permitindo avaliar com precisão as variáveis-chave: Estação, Linha, Ano, Mês e Média Diária de Passageiros. Como limitação conhecida, destaca-se a natureza agregada mensal dos dados, o que impossibilita a análise do comportamento intradiário (como os horários de pico específicos da manhã ou da tarde), mas que se mostra perfeitamente robusta para o mapeamento macroscópico da pressão no sistema.

4. OS INSIGHTS REVELADOS (Análise Exploratória)

A análise exploratória de dados quebrou suposições gerais e trouxe à tona fatos numéricos contundentes e alarmantes sobre a assimetria do fluxo de passageiros:

- **O Epicentro da Pressão:** Os dados comprovaram de forma isolada que a **Estação SÉ** é o ponto mais crítico e sobrecarregado de toda a malha metroviária. Por ser o ponto central de

conexão entre a Linha 3-Vermelha e a Linha 1-Azul, a Sé registrou a marca impressionante de aproximadamente **212 mil passageiros diários** em seus períodos de maior movimento com base nos dados de 2025.

TOP 10 ESTAÇÕES MAIS LOTADAS			
	Estacao	Linha	Passageiros
42	SÉ ¹	LINHA 3-VERMELHA	212.0
41	SÉ (1)	LINHA 3-VERMELHA	202.0
26	PALMEIRAS-BARRA FUNDA ²	LINHA 3-VERMELHA	151.0
25	PALMEIRAS-BARRA FUNDA (2)	LINHA 3-VERMELHA	146.0
33	REPÚBLICA ³	LINHA 3-VERMELHA	127.0
32	REPÚBLICA (3)	LINHA 3-VERMELHA	121.0
16	CONSOLAÇÃO *	LINHA 2-VERDE	105.0
15	CONSOLAÇÃO (4)	LINHA 2-VERDE	100.0
13	CHÁCARA KLABIN ³	LINHA 2-VERDE	90.0
52	VILA PRUDENTE ¹	LINHA 2-VERDE	90.0

- **A Assimetria das Linhas:** Há uma profunda heterogeneidade na distribuição da demanda. O estudo revelou uma concentração massiva nas estações da Linha 3-Vermelha. Além da Sé, estações de grande integração logística como **Palmeiras-Barra Funda** e **República** despontam logo em seguida no ranking de maior fluxo.
- **O Comportamento Temporal:** Embora exista uma variação natural do fluxo ao longo dos meses do ano (influenciada por períodos de férias e recessos), os dados mostram que a pressão de superlotação mantém uma regularidade alta na maior parte das janelas temporais. A comparação direta entre 2025 e 2026 confirmou que a dinâmica de alta concentração nos mesmos nós estratégicos permanece crônica, demandando soluções estruturais de longo prazo.

5. A RESOLUÇÃO (Resultados Pretendidos e Impacto)

A união entre dados, narrativa e visualização cumpre aqui o seu papel principal: **provocar mudanças**. Através deste estudo exploratório, os dados brutos e frios das planilhas governamentais foram transformados em um mapa estratégico visível de vulnerabilidade do transporte.

Com as conclusões e os rankings obtidos, a governança e os planejadores metroviários obtêm embasamento técnico e visual para:

1. Priorizar investimentos de expansão física e otimização de plataformas nos gargalos mais severos identificados (eixo Sé - Barra Funda);
2. Direcionar frotas operacionais e contingenciamento de segurança de forma preditiva com base nos meses e pontos de maior saturação.

O projeto cumpre com rigor os objetivos acadêmicos e analíticos da disciplina, disponibilizando um código limpo, documentado e reproduzível no repositório GitHub, demonstrando como a

engenharia de dados pode — e deve — ser utilizada como ferramenta científica para a melhoria da infraestrutura pública e da qualidade de vida na cidade de São Paulo.